GoalGuru

Choaib Goumri - 0512118390

1 INTRODUZIONE

2 MODELLO CRISP - DM

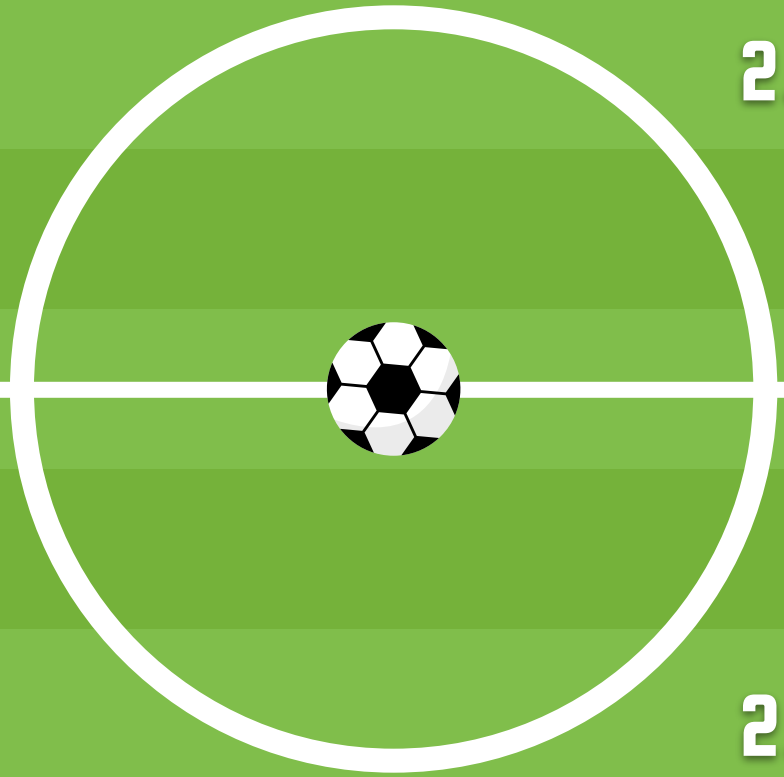

2.1 Business Understanding

2.2 Data Understanding

2.3 Data Preparation

2.4 Data Modeling

2.5 Evaluation

2.6 Deployment

01 INTRODUZIONE

INTRODUZIONE

Negli ultimi anni, l'applicazione **dell'intelligenza artificiale** nel mondo dello sport ha subito **un'evoluzione significativa**, rivoluzionando il modo in cui analisti, appassionati e professionisti interpretano il gioco. **L'analisi predittiva** delle partite di calcio, un campo che fino a poco tempo fa era dominato da **intuizioni soggettive** e **modelli statistici tradizionali**, sta ora beneficiando dei progressi dell'apprendimento automatico. Il **progetto GoalGuru** nasce con l'obiettivo di sfruttare tecniche di **Machine Learning** per fornire previsioni affidabili sui risultati delle partite di calcio, analizzando dati storici e individuando schemi nascosti che possano influenzare gli esiti degli incontri.

Per progettare il nostro modello di AI, abbiamo seguito la metodologia **CRISP-DM**, strutturato e affidabile per progetti di data mining. Questo framework ci ha guidato attraverso fasi chiare: dalla **comprensione del business** e dei **dati alla preparazione**, **modellazione**, **valutazione e implementazione**. Grazie a CRISP-DM, abbiamo ottimizzato il processo, allineato obiettivi e soluzioni tecniche, e garantito un modello efficace e scalabile.

2.1 Business Understanding

Business Understanding

Il progetto mira a creare un modello per prevedere i risultati delle partite di calcio, sfruttando il **machine learning** e dati storici per ottenere previsioni accurate.

Gli obiettivi?

- Migliorare l'**accuratezza** delle previsioni
- Offrire agli utenti **informazioni per scommesse** o analisi sportive
- Aumentare l'engagement spingendoli a seguire più partite e campionati
- **Fidelizzarli** con un servizio di alta qualità che superi le aspettative.

P.E.A.S.

- **Performance**: precisione delle previsioni dei risultati delle partite di calcio.
- **Environment**: contesto delle partite di calcio.
- **Actuators**: l'agente agisce sull'ambiente fornendo previsioni sui risultati delle partite di calcio.
- **Sensors**: l'agente percepisce le informazioni attraverso l'accesso diretto ai dati storici delle partite.

Environment

- **Completamente osservabile**: il dataset fornisce tutte le informazioni necessarie per prendere decisioni
- **Stocastico**: i risultati sono influenzati da molteplici fattori imprevedibili
- **Episodico**: la predizione per una partita non influenza le altre
- **Statico**: l'ambiente non cambia mentre l'agente opera
- **Discreto**: Le variabili sono misurate in valori distinti e ben definiti
- **Ad Agente Singolo**: vi sarà un unico agente ad operare

2.2 Data Understanding

DATASET

Questo dataset contiene **4788** partite di calcio, con dettagli su **statistiche di gioco**, risultati e contesto delle competizioni. Ogni partita è rappresentata con informazioni sulla data, l'orario, la competizione, la sede (casa o trasferta) e il risultato. Le statistiche includono gol fatti e subiti, expected goals (xG), possesso palla, tiri totali, distanza media dei tiri, calci piazzati e rigori. Sono presenti anche dati aggiuntivi come il capitano della squadra e l'arbitro.

Ogni riga collega una squadra al proprio avversario, con **informazioni utili per analisi comparative** o studi sulle performance stagionali. Sebbene la maggior parte delle colonne sia completa, **alcune**, come gli spettatori, **presentano valori mancanti**, e una colonna (notes) è completamente vuota. **Nel complesso**, il dataset offre una **visione dettagliata e versatile**, adatta per analisi statistiche, esplorazioni tattiche o modelli predittivi legati al calcio.

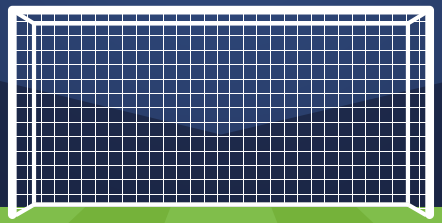

2.3 Data Preparation

PREPROCESSING

Il preprocessing di un dataset complesso implica una serie di operazioni per **trasformare i dati grezzi in un formato utilizzabile** per l'analisi. Dopo un'esplorazione iniziale per comprendere la struttura e individuare anomalie, sono state **rimosse informazioni superflue e ottimizzati i tipi di dato** per ridurre l'occupazione di memoria. **Nuove colonne** sono state aggiunte per estrarre informazioni derivate, mentre dati mancanti o duplicati sono stati gestiti per garantire coerenza. Operazioni come normalizzazioni, calcoli di medie mobili e categorizzazioni hanno ulteriormente arricchito il dataset, rendendolo pronto per analisi più avanzate o applicazioni di machine learning.

PREPROCESSING

Nella fase di Standardizzazione/Normalizzazione viene l'applicazione One-Hot Encoding alle variabili categoriche e StandardScaler per le variabili numeriche.

One-Hot Encoding è una tecnica di codifica che trasforma variabili categoriche in variabili binarie (0 e 1), creando una colonna per ogni categoria.

StandardScaler è una tecnica di standardizzazione che ridimensiona le variabili numeriche affinché abbiano media 0 e deviazione standard 1, migliorando le performance degli algoritmi di Machine Learning.

#Colonne prima	#Colonne dopo
28	24

2.4 Data Modeling

KNN

Il K-Nearest Neighbors (KNN) è un algoritmo di machine learning **supervisionato** utilizzato per problemi di classificazione e regressione. L'idea alla base del KNN è semplice: dato un nuovo punto dati, l'algoritmo **cerca i K punti più vicini** nel dataset di training e assegna al nuovo punto la classe più frequente tra i vicini (per la classificazione) o la media dei valori dei vicini (per la regressione).

Ogni modello viene creato con una **combinazione** specifica **di iperparametri** (n_neighbors, weights, metric) dalla griglia definita.

- **Vicini**: Il parametro n_neighbors controlla quanti vicini considerare per classificare un'istanza.
- **Pesatura**: L'opzione weights determina se tutti i vicini contribuiscono ugualmente alla classificazione (uniform) o se i vicini più vicini hanno più peso (distance).
- **Distanza**: Il parametro metric specifica la metrica di distanza utilizzata (euclidea o manhattan).

Limiti del KNN

Nonostante la semplicità e l'efficacia in problemi di piccole dimensioni, il KNN presenta alcuni limiti:

Ogni modello viene creato con una **combinazione** specifica **di iperparametri** (n_neighbors, weights, metric) dalla griglia definita.

- **Sensibilità alla scelta di k:** Un valore di k troppo piccolo rende il modello sensibile al rumore, mentre un valore troppo grande riduce la capacità di catturare le variazioni locali.
- **Scalabilità**: Il KNN diventa inefficiente con dataset di grandi dimensioni, poiché ogni nuova predizione richiede il calcolo della distanza con tutti i punti di training.
- **Difficoltà con dati complessi**: In problemi con distribuzioni più intricate, il KNN può avere difficoltà a generalizzare

Superamento dei limiti con una Rete Neurale

- Abbiamo eseguito **un'analisi dettagliata delle performance** dei modelli nella fase di valutazione, concentrandoci su **metriche chiave come accuratezza, tempo di esecuzione e capacità di generalizzazione.**

- Dai risultati ottenuti, **abbiamo osservato che il KNN**, pur essendo **efficace in scenari con dataset di piccole dimensioni** e distribuzioni relativamente semplici, **non riusciva a catturare adeguatamente pattern complessi nei dati**, risultando meno performante rispetto ad approcci più avanzati.

- Questo ci ha portato a **considerare metodi in grado di superare queste limitazioni,** valutando le loro prestazioni su diversi set di dati e individuando una soluzione che garantisse un migliore equilibrio tra accuratezza, efficienza computazionale e capacità di adattamento alle caratteristiche del problema.

RETE NEURALE

La rete neurale è composta da due strati densi (dense layers) e da un layer di dropout. Ogni strato denso è completamente connesso.

- **Input**: Il modello riceve in ingresso variabili numeriche e categoriche, con una dimensione determinata dal numero di variabili nel dataset.
- **Strato nascosto 1**: Un primo strato denso con un numero di neuroni definito da iperparametri.
- **Strato nascosto 2**: Un secondo strato denso, anch'esso con neuroni regolati da iperparametri.
- **Dropout**: Un livello di dropout (10%) applicato dopo il secondo strato per evitare overfitting, disattivando casualmente alcuni neuroni durante l'addestramento.
- **Output**: Uno strato denso con 3 neuroni (vittoria, pareggio, sconfitta) e attivazione softmax, che restituisce le probabilità per ciascuna classe, sommate a 1.

ESEMPIO RETE NEURALE

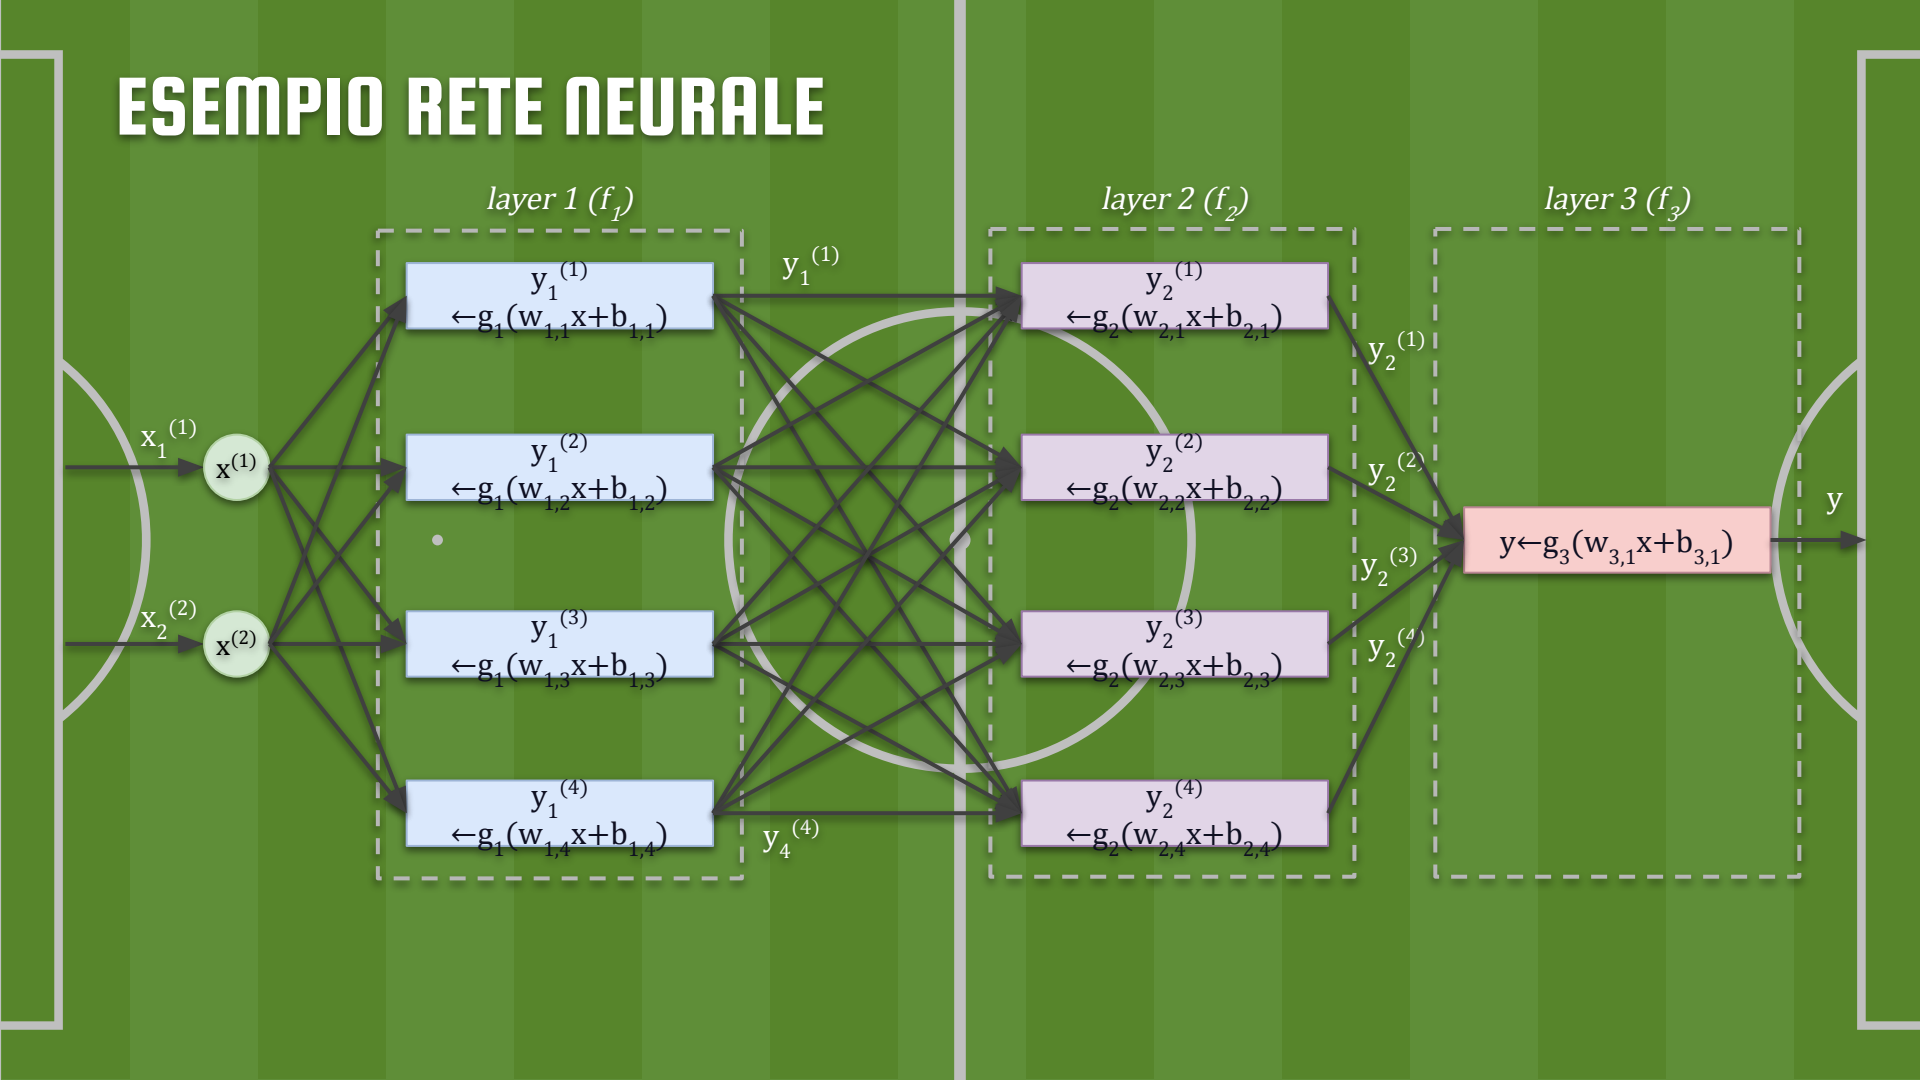

IPERPARAMETRI

Sono parametri che **controllano il processo di apprendimento** del modello, ma non vengono appresi dai dati. Servono per **ottimizzare l'apprendimento**, fornendo al modello gli strumenti migliori per imparare.

- **learning_rate**: Determina quanto velocemente i pesi vengono aggiornati. Un valore troppo alto può causare instabilità, uno troppo basso può rallentare l'apprendimento.

- **epochs**: Il numero di volte che l'intero dataset viene passato nella rete. Troppo poche epoche possono portare a underfitting, troppe a overfitting.

- **neurons_1layer e neurons_2layer**: Il numero di neuroni nei rispettivi strati nascosti. Più neuroni possono aumentare la capacità di apprendimento, ma aumentano il rischio di overfitting.

- **activation_functions**: Funzioni che determinano come i neuroni attivano i segnali. Le più comuni sono:
  - ReLU: Attiva valori positivi, azzera quelli negativi. Veloce e comune.
  - Sigmoid: Mappa valori tra 0 e 1. Utile per classificazione binaria.
  - Tanh: Mappa valori tra -1 e 1.

- **batch_size**: Il numero di esempi elaborati prima di aggiornare i pesi. Batch più grandi rendono l'apprendimento più stabile, ma richiedono più memoria.

Grid Search

Viene utilizzato il grid search per **testare diverse combinazioni di iperparametri**, come il numero di neuroni negli strati nascosti, la funzione di attivazione, il learning rate, il numero di epoche e la dimensione del batch. **Ogni combinazione viene valutata** e il modello con la minore perdita di validazione viene scelto come migliore.

Random Search

Viene utilizzato il grid search per **testare diverse combinazioni di iperparametri**, come il numero di neuroni negli strati nascosti, la funzione di attivazione, il learning rate, il numero di epoche e la dimensione del batch. **Ogni combinazione viene valutata** e il modello con la minore perdita di validazione viene scelto come migliore.

2.5 Evaluation

Analisi dell'Accuratezza di validazione KNN

Intervallo di accuratezza: 0.56–0.60, con un massimo di **0.60** alla combinazione **15.0 (indice 17.5)**.

- **Distribuzione non uniforme**: Solo **4 su 18 combinazioni** superano 0.59 → pochi iperparametri sfruttano il pieno potenziale del modello.
- **Sensibilità ai parametri**:

  - Learning rate **> 0.01** → calo di accuratezza (0.56), segno di instabilità.
  - Regolarizzazione moderata (**L2 = 0.001**) → migliora la generalizzazione.
    - **Limiti intrinseci**: Accuratezza max 60% potrebbe dipendere da **rumore nei dati, feature poco informative o squilibrio di classe**.

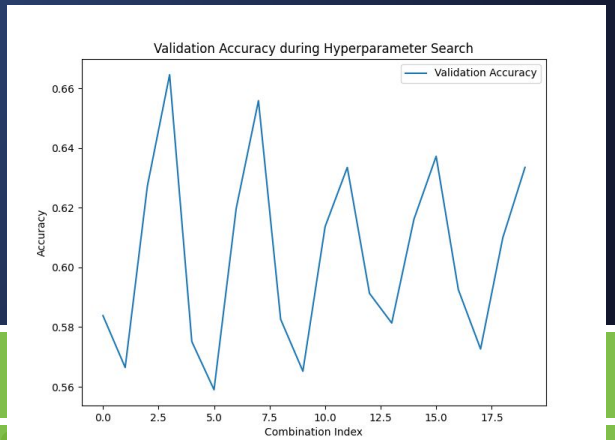

Confronto Grid Search vs. Random Search

- **Grid Search (GS)**
- ✅ **Andamento della loss**: da **1.05** → **0.75** in 5 epoche (**Δ0.06 per epoca**).
  ✅ **Saturazione** dopo 3 epoche (**Δ < 0.02 per epoca**).
  ⚠️ **Costo computazionale**: **12h** su CPU Intel i7, 16GB RAM.
- **Random Search (RS)**
- ✅ **Andamento della loss**: da **0.75** → **0.68** in 4 epoche (**Δ0.12 per epoca**).
  ✅ **Esplora il 30% in meno** di combinazioni → più efficiente.
  ✅ **Tempo di training**: **6h** → riduzione del costo computazionale.
- 🔑 **Key Insights**
  ✔ **RS converge più velocemente** (loss inferiore: **0.68 vs. 0.75**).
  ✔ **Maggiore stabilità** (varianza inter-epoca ridotta).
  ✔ **Trade-off**: **GS** esplora più a fondo, utile per domini ben definiti,

  mentre **RS** ottimizza il tempo di ricerca.

MIGLIORI IPERPARAMETRI (Grid Search)

Grid Search | 218:44 | Random Search

Learning Rate	0.001
Epochs	8
Numero di Neuroni (Layer 1)	55
Numero di Neuroni (Layer 2)	50
Funzione di Attivazione	ReLu
Batch Size	200

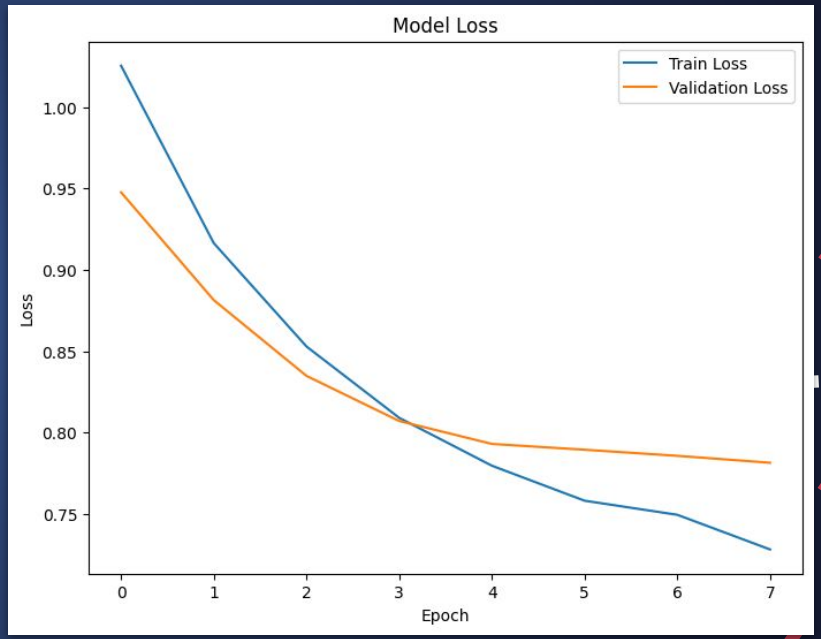

2.6 Deployment

Deployment

- **Obiettivo**: Integrare il modello in un ambiente operativo per inferenze rapide, scalabili e affidabili.
- **Sfide principali**:

  - **Scalabilità**: Gestione efficiente di richieste crescenti.
  - **Affidabilità**: Disponibilità e resilienza del servizio.
  - **Manutenibilità**: Aggiornamenti senza interruzioni.

Attività del Deployment

✅ **Salvataggio dei risultati** → `test_results.txt` documenta **accuratezza, precision, recall, F1-score**.
✅ **Analisi errori** → **Matrice di confusione** (`matrice_di_confusione.png`) per ottimizzazione modello.
✅ **Esportazione modello** → `best_model.h5` pronto per:

- **API REST** (Flask, FastAPI, Django).
- **Cloud Deployment** (AWS, Google AI Platform, Azure).
- **Edge Computing** (dispositivi locali per bassa latenza).

CONCLUSIONI

Il modello è stato testato, ottenendo una **precisione del 67%** e una **perdita di 78.11%**.
Mentre la **precisione è accettabile**, la **perdita** relativamente **alta indica che il modello commette ancora molti errori**. Questo suggerisce che ci sia spazio per miglioramenti, ad esempio ottimizzando ulteriormente gli iperparametri o applicando tecniche di regolarizzazione per affinare le prestazioni.

Goal Guru ha sviluppato un **workflow completo di deployment ML**, con un'API operativa e scalabile, pronta per future integrazioni e ottimizzazioni.

GRAZIE!

Choaib Goumri - 0512118390